

# Reconocimiento de actividad humana basado en lecturas de sensores y diferentes metodos de clasificación.

Marco Loaiza  
Departamento de Ingenieria Electrónica  
Pontificia Universidad Javeriana  
Bogota, Colombia  
Email: {[loaiza-m](mailto:loaiza-m@javeriana.edu.co)}@javeriana.edu.co

**Abstract**— Este trabajo presenta el desarrollo de diferentes modelos de clasificacion para determinar la actividad que se encuentra realizando una persona a partir de datos generados por sensores.

El objetivo del paper es probar diferentes metodos de clasificacion y poderlos comparar para identificar el mejor modelo de actividad del usuario.

**Index Terms**— *Actividad humana, modelos de clasificación, datos de sensores.*

## I. INTRODUCTION

El reconocimiento de actividad humana es una introducción a la tecnología de actividad que permite a un sistema detectar las actividades de los seres humanos tales como: sentarse, pararse, caminar, correr, saltar, subir escaleras, bajar escaleras entre otras, utilizando un dispositivo de captura de esta información como lo son cámaras y sensores.

Esta información es importante para muchas aplicaciones como cuidado personal, rehabilitación y entretenimiento dentro de casa. Los registros de actividad diaria pueden ayudar en el manejo de enfermedades crónicas y fisioterapias al igual que poder monitorear en tiempo real las actividades nos ayuda por ejemplo a detectar la caída accidental de un anciano que vive solo, dentro del campo del entretenimiento esta tecnología también puede ayudar al desarrollo de videojuegos que cambian la forma de interacción del jugador.[1]

En la actualidad gracias al gran desarrollo tecnológico, estas medidas pueden ser tomadas en tiempo real para su procesamiento mediante sistemas embebidos, los cuales para nuestro caso de estudio, integran sensores como acelerómetros y giroscopios capturando una gran cantidad de datos para su posterior análisis.[2]

En este estudio se utiliza una base de datos tomada del repositorio de kaggle que contiene aproximadamente 88.500 muestras etiquetadas, recolectadas con el sensor de acelerómetro y giroscopio de un iPhone con un intervalo de toma de medidas de 10 segundos y una frecuencia de 5Hz, de una persona que se encuentra corriendo y caminando.[3]

## II. Documento

El documento se encuentra dividido en 5 segmentos donde se describe:

### A. Estado del arte.

Se realiza una primera revisión del estado del arte existente sobre el tema propuesto que sirva como referencia o guía durante el desarrollo proyecto.

### B. Analisis de datos.

Se realiza una primera revision de los datos obtenidos en el base de datos de kaggle dando información de las variables, y realizando un analisis descriptivo de los datos su comportamiento, mínimos y máximos entre otros.

### C. Creacion del vector de características.

Posterior a esto se realiza la seleccion de las variables que serán tenidas en cuenta por el modelo, generando nuevas variables o transformaciones apartir de las analizadas con el objetivo de definir y crear el vector de características que utilizaran los modelos.

### D. Selección y evaluación de modelos.

En esta seccion se realiza un analisis de los modelos para identificar los modelos a utilizar y revision de su ejecucion

### E. Conclusiones

Finalmente presentan las conclusiones del proyecto desarrollado a partir del desarrollo y ejecución del mismo.

## III. Desarrollo del Proyecto

### A. Estado del arte.

Revisando bibliografía y documentos, papers expuestos anteriormente se encuentra que ya se han realizado varios experimentos relacionados con el reconocimiento de la

actividad humana, se pueden destacar varios métodos como el procesamiento de señales para la clasificación de las actividades y el uso de modelos de clasificación a partir de datos proporcionados por sensores utilizando machine learning.

También se encuentran recomendaciones para tratar las variables obtenidas del sensor como aceleración y giroscopio realizar un analisis creando una ventana de tiempo que permita capturar información o patron de movimiento realizado por el humano, si se toman los datos individuales, podría no capturarse esta información para el desarrollo del clasificador.

Con esta información se procede a realizar el analisis inicial de los datos obtenidos.

#### A. Analisis de datos.

La información utilizada para este proyecto se encuentra en el repositorio de información de la página kaggle, la cual es libre y esta disponible con el nombre de: “Run or Walk A dataset containing labeled sensor data from accelerometer and gyroscope”[3].

La base de datos contiene información de una persona corriendo y caminando, los datos son generados por un aplicativo móvil de apple el cual utiliza los sensores del celular para medir las variables de aceleración y giroscopio dispuestas en el archivo.

El dataset contiene 88588 muestras tomadas de los sensores de un iphone 5c la cual toma estas muestras en un intervalo de 10 segundos y con una frecuencia de 5.4 Hz.

Las variables que se encuentran en el dataset son nombre del usuario, tiempo y día, una variable llamada “wrist” la cual indica en que muñeca llevaba colocado el celular al momento de recolectar las muestras indicando un 1 si estaba en la muñeca derecha y 0 en la muñeca izquierda.

Otra variable presentada es la de actividad la cual indica si el usuario estaba caminando con un valor de 0 o corriendo con un valor de 1, finalmente se presentan las variables de los valores capturados del acelerómetro en los ejes x,y,z y del giroscopio en los mismos ejes.

date	time	user	wrist	activity	Ax	Ay	Az	Gx	Gy	Gz
------	------	------	-------	----------	----	----	----	----	----	----

En el analisis de la información presentada se encuentra que todas las muestras son del mismo sujeto es decir solo se tuvo en cuenta una persona para medir las variables, con la información del día y tiempo se observa que se tomaron muestras durante 12 días diferentes a distintas horas, existen mas muestras recolectadas utilizando el dispositivo en la mano derecha que en la mano izquierda en aproximadamente 4.000 muestras finalmente la cantidad de muestras de actividad caminando y corriendo es aproximadamente la misma 44.200

con una diferencia de 146 muestras de mas para la actividad corriendo.

Para evitar un viciamiento del modelo por tener mas muestras de una clase se realiza un balanceo de datos para garantizar que existan igual numero de muestras caminando y corriendo.

Posterior a esto se realiza un analisis de datos faltantes sobre las variables donde la base de datos demuestra ser de gran utilidad al tener todos los datos limpios y consistentes.

Se observa que la distribución de los datos tiene un comportamiento gaussiano en ambas actividades una con alta curtosis en la s muestras caminando y baja curtosis en las muestras corriendo para las aceleraciones x-z, en el caso de la aceleración y se observa bimodal los comportamientos con una curtosis similar.




Figura 1 Distribución aceleración x




Figura 2 Distribución aceleración y

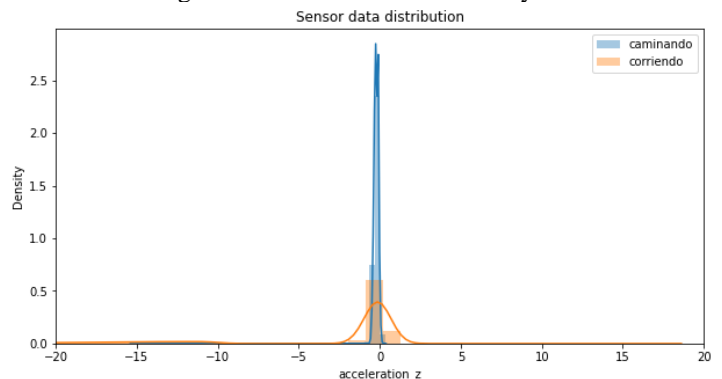


Figura 3 Distribución aceleración z

De acuerdo a los artículos investigados previamente el modelo puede realizar una buena clasificación de las actividades utilizando solo los datos de aceleración de los tres ejes, apartir de los cuales se pueden generar nuevas variables junto con la variable de etiqueta “activity”, por lo cual se eliminan las variables de nombre, fecha y tiempo, wrist y las variables correspondientes al giroscopio.

### B. Creacion del vector de características.

Como muestran los trabajos y proyectos relacionados, las características de bajo nivel (que son fácilmente computables) son lo suficientemente significativas como para clasificar la actividad correcta. Para la extracción de características, se implementará y evaluará un enfoque de ventana deslizante con una duración de dos segundos y una superposición del 50%. Investigaciones anteriores muestran que este es un tamaño de ventana deslizante adecuado para el reconocimiento de actividad [4][5]–[7]. Por lo general, en dos segundos se debe completar al menos una repetición de una actividad. Dentro de cada ventana, se extraerán las características que se enumeran a continuación para cada variable de aceleración.

Nombre	Definición	Abreviacion
Media	Media de la aceleracion por cada eje(x,y,z) y las tres juntas (xyz)	mean
Varianza	Varianza de la aceleracion por cada eje(x,y,z) y las tres juntas (xyz)	var
Máximo	Valor máximo de la aceleracion por cada eje(x,y,z) y las tres juntas (xyz)	max
Mínimo	Valor máximo de la aceleracion por cada eje(x,y,z) y las tres juntas (xyz)	min
Desviación estandar	Desviación estandar de la aceleracion por cada eje(x,y,z) y las tres juntas (xyz)	sd
Actividad	Etiqueta o variable de respuesta indica 1 si la persona corre y 0 si camina	activity

Tabla 1 Vector de características.

Se realiza un analisis de correlaciones entre las variables como se observa en la figura 4, como se espera existen correlación entre la desviación estándar y varianza de los ejes. Por el momento y con el respaldo de que los modelos estudiados en los documentos se ejecutan correctamente, no se propone realizar un analisis de componentes principales hasta probar el modelo con las variables completas.

En caso de que la clasificación del modelo no supere el 75 % de precisión después de un primer analisis, se realizara PCA para disminuir el numero de variables eliminando esta correlación presentada.




Figure 4 Correlación del vector de características

### C. Selección y evaluación de modelos.

Con el vector de características ya definido se procede a la selección de los modelos de clasificación y a su posterior evaluación observando la matriz de confusión que nos indica cuantos de los valores de cada clase son catalogados de forma correcta. Para esto primero dividimos la base de datos en una proporción de 80 – 20 para los datos de entrenamiento y de prueba respectivamente.

Dentro de los diferentes modelos que se ejecutan en los analisis de los papers revisados inicialmente los modelos que mejores resultados ofrecen son utilizando el método de maquinas de soporte vectorial [1], [2], [6], [8], y realizan una comparación entre diferentes tipos de algoritmos como vecinos mas cercanos, Naive Bayes, Arboles de decisión [1]

A partir de esta información y los modelos vistos durante el estudio del proyecto se escogen los modelos k vecinos mas cercanos y maquinas de soporte de vectorial.

Se utilizan las funciones de scikit-learn para realizar los modelamientos de los datos, en el caso de vecinos mas cercanos se utiliza la función

`KNeighborsClassifier()`

Con los parámetros por defecto numero de vecinos = 5, Algoritmo = automático, y numero de clases = 2.

En el caso de maquinas de soporte vectorial se utiliza la función

`svm.SVC()`

Con parámetros por defecto kernel = lineal.

A continuación se muestran los resultados obtenidos:

## MODELO KNN




Figure 5 Matriz de confusion modelo KNN

	precision	recall	f1-score	support
0	1.00	1.00	1.00	1809
1	1.00	1.00	1.00	1729
accuracy			1.00	3538
macro avg	1.00	1.00	1.00	3538
weighted avg	1.00	1.00	1.00	3538

Figure 6 Métricas modelo KNN

## MODELO SVM




Figure 7 Matriz de confusion de modelo SVM

	precision	recall	f1-score	support
0	0.99	1.00	0.99	1809
1	1.00	0.99	0.99	1729
accuracy			0.99	3538
macro avg	0.99	0.99	0.99	3538
weighted avg	0.99	0.99	0.99	3538

0.9943470887507067

Figure 8 Métricas modelo SVM

Como se puede observar en las figuras las métricas de clasificacion de ambos modelos clasifican de una manera muy eficiente obteniendo un bajo error de clasificacion en el caso de KNN solo presenta 4 muestras mal clasificadas de 3534, correspondiente a un error del 0.001% en el caso del modelo SVM obtiene 20 muestras mal clasificadas de las mismos 3534 muestras correspondiente a un error del 0.005%.

## D. Conclusiones

Este Proyecto propone la clasificacion de la actividad humana utilizando sensores de un dispositivo móvil como generador de datos obteniendo buenos resultados para el caso del data set seleccionado, en el cual se toman las muestras de la misma persona la cual posee el mismo patron de caminar y correr, se propone para investigaciones futuras utilizar datos de diferentes personas para realizar un modelo mas general y que pueda ser implementado en los dispositivos IoT que pueden generar gran cantidad de datos en tiempo real y puedan ser analizados para diferentes funciones o aplicaciones por ejemplo en los smartwatch o wearables. También se propone como posible investigación futura obtener información de más actividades y realizar el modelo de clasificacion con mas numero de clases para observar el comportamiento de los clasificadores que en este caso de dos clases es bastante eficiente.

## REFERENCIAS

- [1] F. Yang and L. Zhang, "Real-time human activity classification by accelerometer embedded wearable devices," *2017 4th Int. Conf. Syst. Informatics, ICSAI 2017*, vol. 2018-Janua, no. Icsai, pp. 469–473, 2017, doi: 10.1109/ICSAI.2017.8248338.
- [2] N. Hardiyanti, A. Lawi, Diaraya, and F. Aziz, "Classification of Human Activity based on Sensor Accelerometer and Gyroscope Using Ensemble SVM method," *Proc. - 2nd East Indones. Conf. Comput. Inf. Technol. Internet Things Ind. EIConCIT 2018*, pp. 304–307, 2018, doi: 10.1109/EIConCIT.2018.8878627.
- [3] V. Malyi, "Run or Walk A dataset containing labeled sensor data from accelerometer and gyroscope." 2017, [Online]. Available: <https://www.kaggle.com/vmalyi/run-or-walk>.
- [4] A. B. Chan and N. Vasconcelos, "Counting people with low-level features and bayesian regression," *IEEE Trans. Image Process.*, vol. 21, no. 4, pp. 2160–2177, 2012, doi: 10.1109/TIP.2011.2172800.
- [5] M. Kurz, B. Hiesl, and E. Sonnleitner, "Real-Time Activity Recognition Utilizing Dynamically On-Body Placed Smartphones," no. Section III, pp. 84–87, 2019.
- [6] P. Prasertsung and T. Horanont, "A classification of accelerometer data to differentiate pedestrian state," *20th Int. Comput. Sci. Eng. Conf. Smart Ubiquitous Comput. Knowledge, ICSEC 2016*, pp. 0–4, 2017, doi: 10.1109/ICSEC.2016.7859881.
- [7] E. Kim, S. Helal, and D. Cook, "Human activity recognition and pattern discovery," *IEEE Pervasive Comput.*, vol. 9, no. 1, pp. 48–53, 2010, doi: 10.1109/MPRV.2010.7.
- [8] S. P. Narayanan C. Krishnan, "ANALYSIS OF LOW RESOLUTION ACCELEROMETER DATA FOR CONTINUOUS HUMAN ACTIVITY RECOGNITION Department of Computer Science and Engineering Arizona State University Tempe AZ 85281," *Ieee*, pp. 3337–3340, 2008.